李宗霖

Li, ZongLin

AI SYSTEMS ENGINEER

CONTACT

EMAIL /
zon75611@gmail.com

GITHUB /
github.com/Jo-Leo-35

LINKEDIN /
linkedin.com/in/ethan-li

WEBSITE /
jo-leo-35.github.io/Ethan-Li-website/

TECH STACK

Languages

C/C++ | Python | SQL | MATLAB | Bash

AI / ML / Infra

PyTorch | DeepSpeed | ONNX | RAG | AI Agents

Systems & Cloud

Docker | RabbitMQ | GCP | AWS | FastAPI

EDUCATION

NCKU（國立成功大學）/
資訊工程學系 資訊工程專班 碩士 (GPA 3.9/4)

NCU（國立中央大學）/
數學系 學士（雙主修：物理學系）

SCAN FOR ENGLISH RESUME

/> 專業摘要

具備資訊工程、數學與物理的跨領域背景，並在研究與實作之間維持穩定的工程導向。就讀成大資工所期間，於入學首年完成全部碩士課程，**GPA 3.9/4**，展現快速學習與高強度執行能力。實務上專注於大型語言模型效能優化、系統架構設計與大規模資料流處理，曾協助專案 **降低 70% 訓練運算成本與 75% VRAM 需求**。習慣從底層原理出發分析問題，並將研究思維轉化為可部署、可維運、可擴充的工程方案。

/> 工作經歷

中華資安國際 | AI 工程師 (AI Engineer)

Nov 2024 - Present

- **運算資源最佳化：**在混合 GPU 架構下微調 27B 參數大型語言模型，導入 DeepSpeed ZeRO-2 與 QLoRA 分散式訓練策略，在維持模型品質的前提下，**成功降低約 70% 訓練運算成本**。
- **量化部署與邊緣推論：**以 ONNX 部署模型端點服務，並將權重進行 4-bit (NF4) 量化，讓測試環境的 **VRAM 使用量降低約 75%**，提升邊緣部署可行性。
- **串流資料系統設計：**運用 RabbitMQ 建置高擴展性的分散式資料管線，並以 Facade Pattern 整合多種異質 API，打造可穩定處理 **超過 200 萬筆 Streaming Data** 的系統架構。
- **DevOps 與自動化部署：**將跨伺服器服務全面容器化，部署於 GCP 等雲端環境，讓團隊協作下的系統建置與交付週期**縮短約 80%**。

永豐金控 金融市場處交易部 | 研發實習生

Jan 2023 - Aug 2023

- 開發高併發網路爬蟲與資料整理流程，自動蒐集並清洗市場資訊，支援後續分析與研究。
- 串聯 OpenAI Whisper 與開源語言模型，打造可即時轉錄英文演講並輸出中文重點摘要的自動化流程，協助第一線交易部門**節省約 90% 的人工篩選時間**。

/> 代表專案與學術成果

IEEE ISCAS 2025 國際級發表

// MapLlama - Two-stage LLM Architecture

擔任第一作者，獨立設計應用於複雜地圖拓樸分析的兩階段問答架構，結合檢索與推理流程，並透過完整實驗驗證模型可靠性，最終獲 IEEE ISCAS 2025 收錄。

GovTech 內政黑客松 全國銅牌

// AWS x Ministry of the Interior (2023)

於資料創新應用競賽中，作為總榜**唯一獲獎的學生團隊**成員，負責雲端後端系統開發與高併發巨量資料串接。

成大永豐 AI 獎學金 (Top 9%)

// NCKU x SinoPac Scholarship (2024)

在競爭激烈的評選中，憑藉實務開發能力與在校研究表現獲得肯定，入選全校前 9% 的重點培育學生。

交大科展 銅牌 兼 最佳物理獎

// 思源科學創意大賽

結合機械實作與物理原理，自主設計高精度的複雜機構，最終獲得銅牌與最佳物理獎。