李宗霖

Li, ZongLin

AI SYSTEMS ENGINEER

CONTACT

EMAIL /
zon75611@gmail.com

GITHUB /
github.com/Jo-Leo-35

LINKEDIN /
linkedin.com/in/ethan-li

WEBSITE /
jo-leo-35.github.io/Ethan-Li-website/

TECH STACK

Languages

C/C++ | Python | SQL | MATLAB | Bash

AI / ML / Infra

PyTorch | DeepSpeed | ONNX | RAG | AI Agents

Systems & Cloud

Docker | RabbitMQ | GCP | AWS | FastAPI

EDUCATION

NCKU（國立成功大學）/
資訊工程學系 資訊工程專班 碩士 (GPA 3.9/4)

NCU（國立中央大學）/
數學系 學士（雙主修：物理學系）

SCAN FOR ENGLISH RESUME

/> 專業摘要

具備資訊工程、金融科技、數學與物理的跨領域背景，在研究與工程實務之間保持高度銜接。就讀成大資工所期間，入學首年即修畢全部碩士課程（**GPA 3.9/4**），展現快速學習與高強度執行力。實務專注於大型語言模型效能最佳化、分散式系統架構設計與大規模資料流處理，曾主導專案 **降低 70% 訓練運算成本與 75% VRAM 用量**。擅長從底層原理切入問題，將研究成果轉化為可部署、可維運的工程方案。

/> 工作經歷

中華資安國際 | AI 工程師 (AI Engineer)

Nov 2024 - Present

- **LLM 訓練最佳化：**在多 GPU 環境下微調 27B 參數大型語言模型，採用 DeepSpeed ZeRO-2 與 QLoRA 分散式訓練策略，在維持模型品質的前提下**降低約 70% 訓練運算成本**。
- **模型量化與推論部署：**透過 ONNX Runtime 匯出模型並進行 4-bit NF4 量化，**VRAM 用量降低約 75%**，實現資源受限環境下的低延遲推論。
- **高吞吐資料管線：**運用 RabbitMQ 事件驅動架構設計分散式資料管線，以 Mixin-based OOP Connector 整合 14 種異質資料源，穩定處理**超過 200 萬筆紀錄**。
- **快取架構設計：**設計 Hybrid Cache 機制（Redis + In-Memory），搭配 Circuit Breaker 與 Singleflight 模式，消除高併發推論場景下的快取雪崩問題。
- **容器化與雲端部署：**將 GPU 訓練與推論環境全面容器化，部署於 GCP 與 RunPod，實現標準化開發流程與一鍵可重現部署。

永豐金控 金融市場處交易部 | 研發實習生

Jan 2023 - Aug 2023

- 建置端對端 NLP 自動化流程：串接 Whisper 語音轉文字與 LLM 摘要生成，自動分析聯準會演講內容，協助交易員**節省約 90% 人工篩選時間**。

/> 代表專案與學術成果

IEEE ISCAS 2025 國際會議發表

// MapLlama - Two-stage LLM Architecture（第一作者）

設計檢索→推理的兩階段推論架構，應用於複雜空間查詢；完成模型微調、效能評測與端對端延遲最佳化，論文獲 IEEE ISCAS 2025 收錄。

TIP 威脅情報平台（5 微服務架構）

// Threat Intelligence Platform

主導企業級平台架構設計：FastAPI + Django + Flask 服務層、Elasticsearch 全文檢索、RabbitMQ 非同步任務排程，搭配 9 支自動化 CronJob，部署於 GCP。

GovTech 內政黑客松 全國銅牌

// AWS × 內政部（2024）獲獎團隊中唯一學生隊伍

負責資料管線開發與模型整合，於資料創新應用競賽中獲頒銅獎。

成大永豐 AI 獎學金

// NCKU × SinoPac（2024）Top 9%

競爭型獎學金，依實務開發能力與學術研究表現綜合評選，錄取率前 9%。